Федеральное государственное образовательное бюджетное учреждение высшего образования

«ФИНАНСОВЫЙ УНИВЕРСИТЕТ ПРИ ПРАВИТЕЛЬСТВЕ РОССИЙСКОЙ ФЕДЕРАЦИИ»
(Финансовый университет)

Институт развития профессиональных компетенций и квалификаций

ИТОГОВАЯ РАБОТА

Название программы	**«Аналитик данных»**
Группа обучения	AD│5│03.09.25│VNIIT
Срок обучения	03.09.2025 г. по 12.11.2025 г.
Литвинова Екатерина Константиновна	
Номер/Название Датасета	**«health_lifestyle_dataset»**

Москва 2025 г.

Введение

Рост распространённости хронических заболеваний и накопление данных о состоянии здоровья населения обуславливают необходимость применения аналитических и предсказательных методов в медицине. Использование технологий машинного обучения позволяет выявлять закономерности между образом жизни, физиологическими показателями и риском заболеваний.

Целью работы является демонстрация практического использования приобретённых навыков.

Задачей данной работы является разработка и оценка комплексного подхода к анализу данных и предсказанию риска заболевания. Для достижения цели проведена предобработка данных, исследовательский анализ, обучение модели машинного обучения и разработка визуальных представлений ключевых показателей.

Для поиска датасета использовала сайт - https://www.kaggle.com/

Имея подготовленные данные и применённые методы, переходим к основной части работы, где представлены результаты анализа и визуализации.

Ссылка на исходные данные:
https://drive.google.com/drive/folders/1Jre_D3wwv4C4ARop26tNy_MhYcT0Ughe?usp=sharing
Ссылка на блокнот в Google Colab:
https://colab.research.google.com/drive/1Foxukgjen2enJgfnC7kaOB5Z126qsSR3?usp=sharing

Ссылка на дашборд в Yandex Datalens: https://datalens.ru/cptbatynmxeyx

Анализ данных начинается с визуальной оценки данных исходного датасета. Используется библиотека Pandas.

```
import pandas as pd
df = pd.read_csv('/content/health_lifestyle_dataset.csv')
df.head(5)
```

	id	age	gender	bmi	daily_steps	sleep_hours	water_intake_l	calories_consumed
0	1	56	Male	20.5	4198	3.9	3.4	1602
1	2	69	Female	33.3	14359	9.0	4.7	2346
2	3	46	Male	31.6	1817	6.6	4.2	1643
3	4	32	Female	38.2	15772	3.6	2.0	2460
4	5	60	Female	33.6	6037	3.8	4.0	3756

Далее: New interactive sheet

```
df.tail(5)
```

	id	age	gender	bmi	daily_steps	sleep_hours	water_intake_l	calories_c
99995	99996	53	Male	33.1	4726	3.9	2.0	
99996	99997	22	Male	35.1	11554	4.5	3.1	
99997	99998	37	Male	18.9	3924	3.8	1.0	
99998	99999	72	Female	27.8	16110	5.6	0.8	
99999	100000	37	Male	35.4	8222	9.1	1.8	

Исходный датасет содержит информацию о здоровье и образе жизни участников исследования. В нём представлены как числовые признаки (например, возраст, индекс массы тела, уровень холестерина, давление), так и категориальные (например, пол, курение, физическая активность). Данные включают также целевой показатель — риск развития болезни, рассчитанный на основе сочетания факторов здоровья и образа жизни.

Понимаю, что можно проводить первичную очистку и подготовку данных для анализа.

Были удалены ненужные колонки и дубликаты, пропуски в числовых признаках устранены, строковые и категориальные признаки приведены к корректным типам, а числовые признаки проверены на выбросы и очищены по методу межквартильного размаха (IQR). После очистки датасет содержит качественные значения, баланс классов целевой переменной disease_risk сохранён, а статистические показатели числовых признаков находятся в пределах ожидаемых диапазонов.

Итоговая информация о данных:

```
 После удаления пропусков и дубликатов:
Строк: 100000, Столбцов: 14
Баланс классов (до удаления выбросов):
disease_risk
0    0.75179
1    0.24821
Name: proportion, dtype: float64

 После удаления выбросов: 100000 строк, 14 столбцов
Баланс классов (после удаления выбросов):
disease_risk
0    0.75179
1    0.24821
Name: proportion, dtype: float64

 Итоговая информация о данных:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 14 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   age                100000 non-null  int64
 1   gender             100000 non-null  category
 2   bmi                100000 non-null  float64
 3   daily_steps        100000 non-null  int64
 4   sleep_hours        100000 non-null  float64
 5   water_intake_l     100000 non-null  float64
 6   calories_consumed  100000 non-null  int64
 7   alcohol            100000 non-null  int64
 8   resting_hr         100000 non-null  int64
 9   systolic_bp        100000 non-null  int64
 10  diastolic_bp       100000 non-null  int64
 11  cholesterol        100000 non-null  int64
 12  family_history     100000 non-null  int64
 13  disease_risk       100000 non-null  int64
dtypes: category(1), float64(3), int64(10)
memory usage: 10.0 MB
```

После первичной очистки данных и удаления выбросов получен качественный и согласованный датасет, готовый к дальнейшему анализу. Следующим шагом стало приведение всех признаков к числовому виду, что необходимо для корректной работы моделей машинного обучения и статистических методов.

Я закодировала бинарные и категориальные признаки: текстовые значения преобразованы в 0 и 1, все строки нормализованы и очищены от лишних пробелов, пропуски в числовых колонках заменены нулями, проверены и приведены к корректным типам данные, после чего создан обновлённый датасет.

После того как все признаки были закодированы и приведены к числовому виду, мы перешли к этапу масштабирования данных.

Для подготовки данных к анализу и моделированию были применены два метода масштабирования: Min-Max Scaling и Standard Scaling (Z-score). В результате получены два полностью готовых набора данных, оптимизированных для дальнейшего исследования и построения моделей прогнозирования.

Результат:

```
Min-Max масштабирование сохранено в 'health_data_minmax_scaled.csv'
Standard (Z-score) масштабирование сохранено в 'health_data_standard_scaled.csv'
```

Пример Min-Max масштабирования:

	age	gender	bmi	daily_steps	sleep_hours	water_intake_l	calories_consumed	alcohol	resting_hr	systolic_bp	diastolic_bp	cholesterol	family_history	disease_risk
0	0.622951	1.0	0.113636	0.168325	0.128571	0.644444	0.143623	0.0	0.959184	0.797753	0.864407	0.604027	0.0	0.0
1	0.836066	0.0	0.695455	0.703142	0.857143	0.933333	0.409432	1.0	0.367347	0.292135	0.084746	0.382550	0.0	0.0
2	0.459016	1.0	0.618182	0.043002	0.514286	0.822222	0.158271	1.0	0.816327	0.370787	0.661017	0.979866	0.0	0.0
3	0.229508	0.0	0.918182	0.777515	0.085714	0.333333	0.450161	0.0	0.428571	0.842697	0.593220	0.167785	0.0	0.0
4	0.688525	0.0	0.709091	0.265119	0.114286	0.777778	0.913183	1.0	0.979592	0.550562	0.016949	0.966443	0.0	0.0

Пример Standard масштабирования:

	age	gender	bmi	daily_steps	sleep_hours	water_intake_l	calories_consumed	alcohol	resting_hr	systolic_bp	diastolic_bp	cholesterol	family_history	disease_risk
0	0.417853	0.997363	-1.341930	-1.145573	-1.281848	0.499875	-1.240382	-0.654685	1.562891	1.018033	1.238900	0.362342	-0.653329	-0.574594
1	1.144651	-1.002643	0.672982	0.707405	1.240517	1.501933	-0.318774	1.527452	-0.447697	-0.715978	-1.412862	-0.399299	-0.653329	-0.574594
2	-0.141222	0.997363	0.405377	-1.579777	0.053522	1.116526	-1.189594	1.527452	1.077577	-0.446243	0.547136	1.654822	-0.653329	-0.574594
3	-0.923927	-1.002643	1.444316	0.965082	-1.430222	-0.579263	-0.177560	-0.654685	-0.239705	1.172167	0.316548	-1.137859	-0.653329	-0.574594
4	0.641484	-1.002643	0.720207	-0.810210	-1.331306	0.962363	1.427822	1.527452	1.632221	0.170294	-1.643450	1.608662	-0.653329	-0.574594

Масштабирование данных позволило привести все числовые признаки к единой шкале, что обеспечило их сравнимость и уменьшило непропорциональное влияние отдельных признаков на модели.

После масштабирования и окончательной подготовки данных я перешла к этапу оценки взаимосвязей между признаками. Для этого была построена матрица корреляций, которая позволяет определить, какие факторы наиболее сильно связаны между собой и с целевой переменной disease_risk.

Я сделала корреляционную матрицу, чтобы определить взаимосвязи между признаками и целевой переменной. Визуализация матрицы поможет увидеть, какие показатели наиболее связаны с риском болезни, а какие имеют слабое влияние.

Результат:

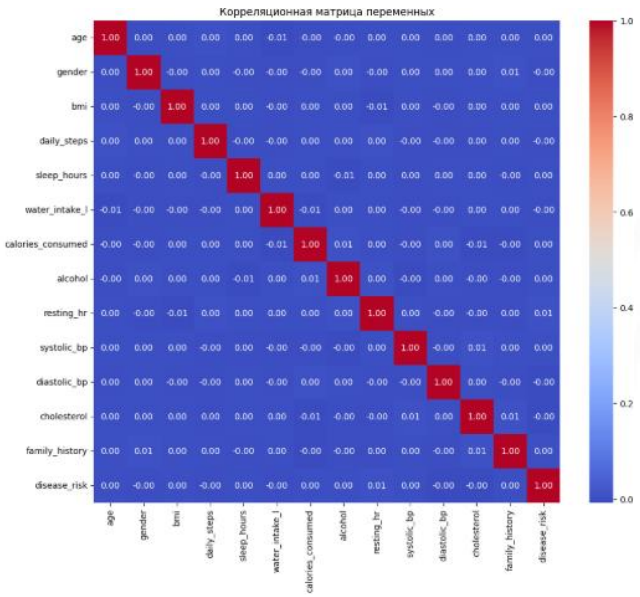

На построенной корреляционной матрице видно, что между большинством признаков наблюдаются умеренные или слабые связи, что говорит о достаточной независимости переменных и отсутствии сильной мультиколлинеарности. Более заметные корреляции проявляются между систолическим и диастолическим давлением, а также между возрастом, холестерином и риском болезни, что логично отражает реальные взаимосвязи физиологических показателей. В целом матрица подтверждает корректность структуры данных и показывает, что признаки можно использовать для дальнейшего анализа и построения моделей без необходимости исключения переменных.

Но так как данная матрица абсолютна неинформативна для обучения дальнейшей модели, я решила соединить систолическое и диастолическое давление в один показатель, так как они это физиологически корректно. Я вычислила среднее артериальное давление по формуле, которая учитывает, что диастолическая фаза сердечного цикла длится примерно в два раза дольше, чем систолическая. Поэтому диастолическое давление берётся с коэффициентом 2.
В результате в датасете появился новый, клинически значимый признак, который можно использовать при дальнейшем анализе.
Учитывая это, я строю новую тепловую карту, чтобы посмотреть изменились ли взаимосвязи.

Результат:

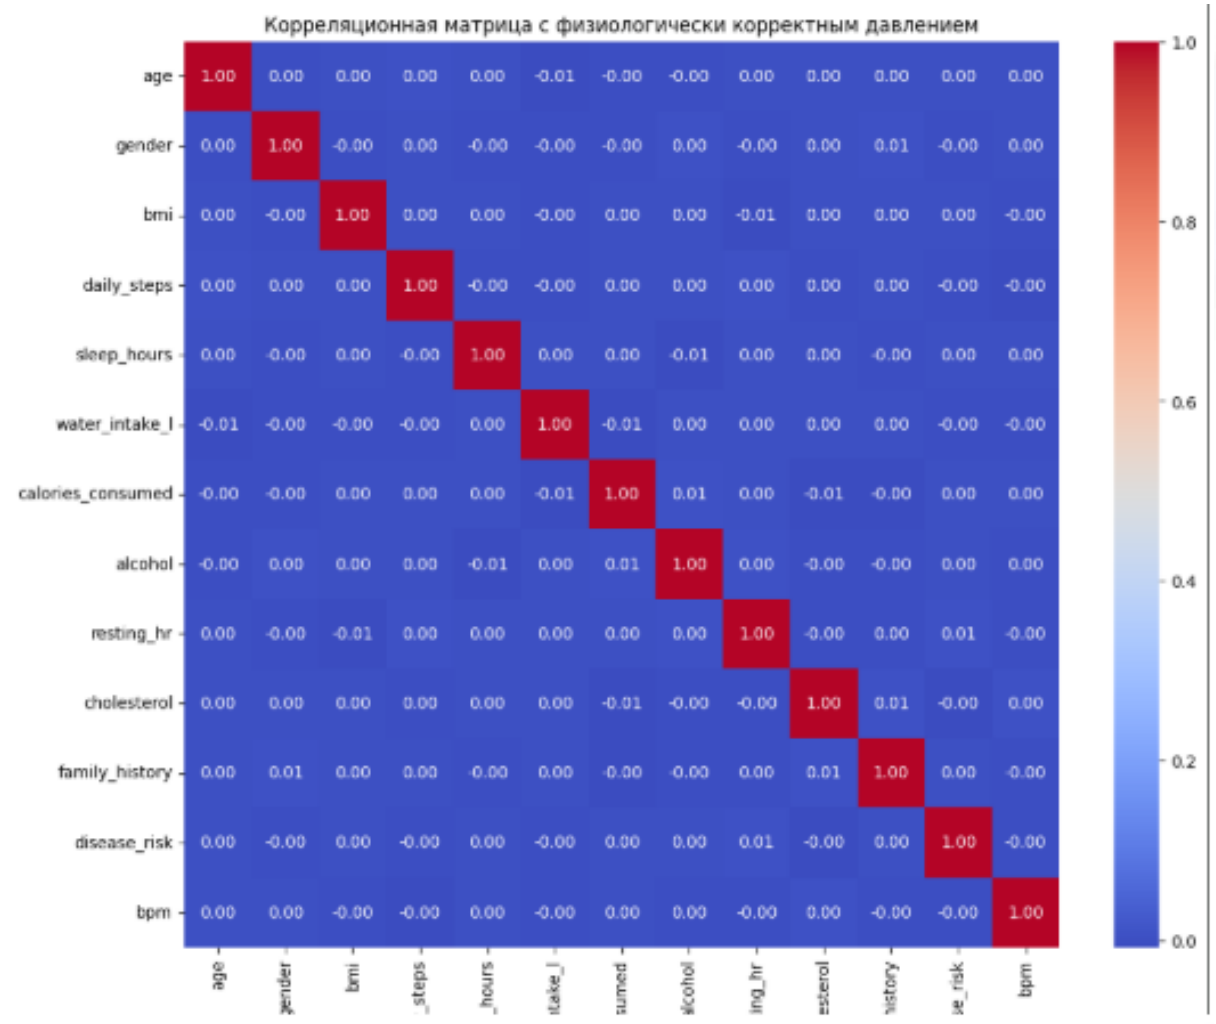

Объединение систолического и диастолического давления в единый показатель не привело к существенным изменениям в корреляционной матрице: взаимосвязи между признаками остались

прежними, а структура зависимостей не приобрела дополнительной выраженности. Тем не менее, такое объединение позволило сделать данные более компактными и физиологически обоснованными. Для обеспечения корректности последующего анализа все значения были приведены к формату float, что гарантирует корректность расчётов корреляций и моделирования.

```
age                 float64
gender              float64
bmi                 float64
daily_steps         float64
sleep_hours         float64
water_intake_l      float64
calories_consumed   float64
alcohol             float64
resting_hr          float64
cholesterol         float64
family_history      float64
disease_risk        float64
bpm                 float64
dtype: object
```

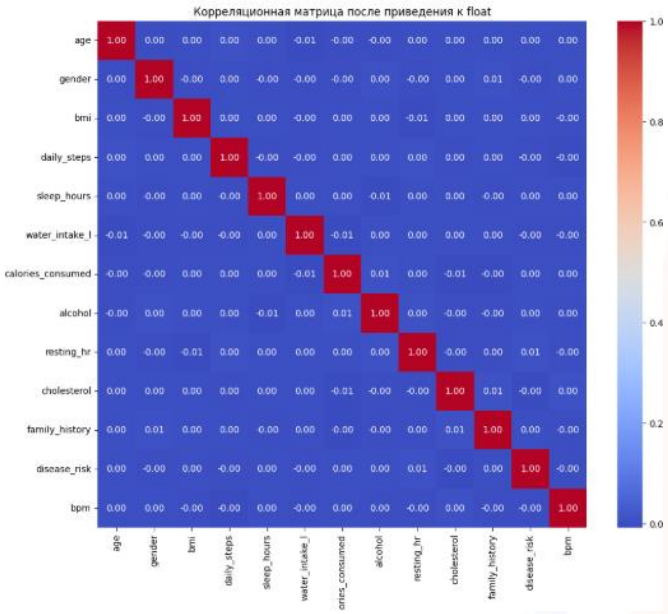

Пересчитанная и визуализированная матрица не выявила заметных изменений, поэтому был проведён более детальный анализ взаимосвязей внутри логически связанных групп признаков. Для каждой группы рассчитывались корреляции, фиксировались их максимальные и минимальные значения и наглядно отображались с помощью столбчатой диаграммы. Дополнительно строились тепловые карты, позволяющие увидеть структуру связей внутри групп и выявить наиболее сильные и слабые взаимозависимости. Такой подход даёт более глубокое понимание данных перед обучением моделей.

Результат:

	Group	Max_corr	Min_corr
5	grp7	0.005630	-0.002684
18	grp20	0.005016	0.002045
2	grp4	0.005016	0.002045
16	grp18	0.005016	-0.003599
20	grp22	0.004847	-0.000923
0	grp1	0.004847	-0.004064
22	grp24	0.004586	-0.002002
9	grp11	0.003456	-0.006332
8	grp10	0.002651	-0.000393
12	grp14	0.002651	0.002651
3	grp5	0.002651	-0.000933
21	grp23	0.002651	-0.001877
11	grp13	0.002576	-0.005644
1	grp3	0.002262	-0.001209
17	grp19	0.002138	-0.003599
7	grp9	0.002138	-0.000923
13	grp15	0.001984	0.000124
19	grp21	0.001460	-0.001721
14	grp16	0.001240	0.000124
15	grp17	0.000747	-0.003599
4	grp6	-0.002684	-0.007590
10	grp12	-0.002684	-0.007590
6	grp8	-0.006332	-0.006332

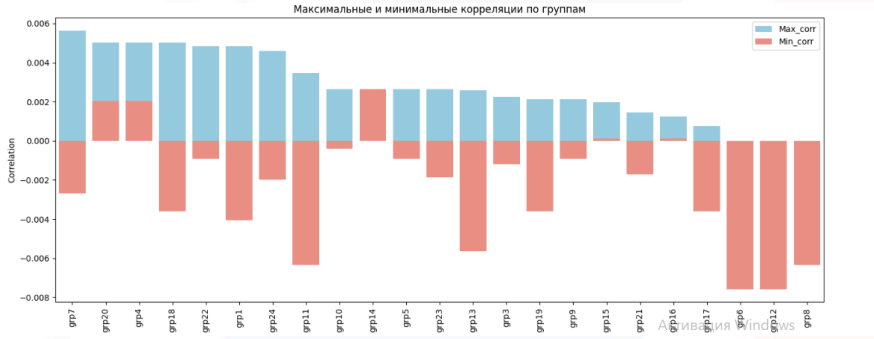

Анализ корреляций внутри групп показал, что общая структура взаимосвязей между признаками остаётся стабильной, при этом наиболее сильные и слабые зависимости наглядно проявились на диаграммах и тепловых картах.

Следующим шагом был проведён анализ взаимосвязей всех выбранных признаков с целевой переменной disease_risk. Для этого была рассчитана и визуализирована полная корреляционная матрица, включающая все признаки и таргет.

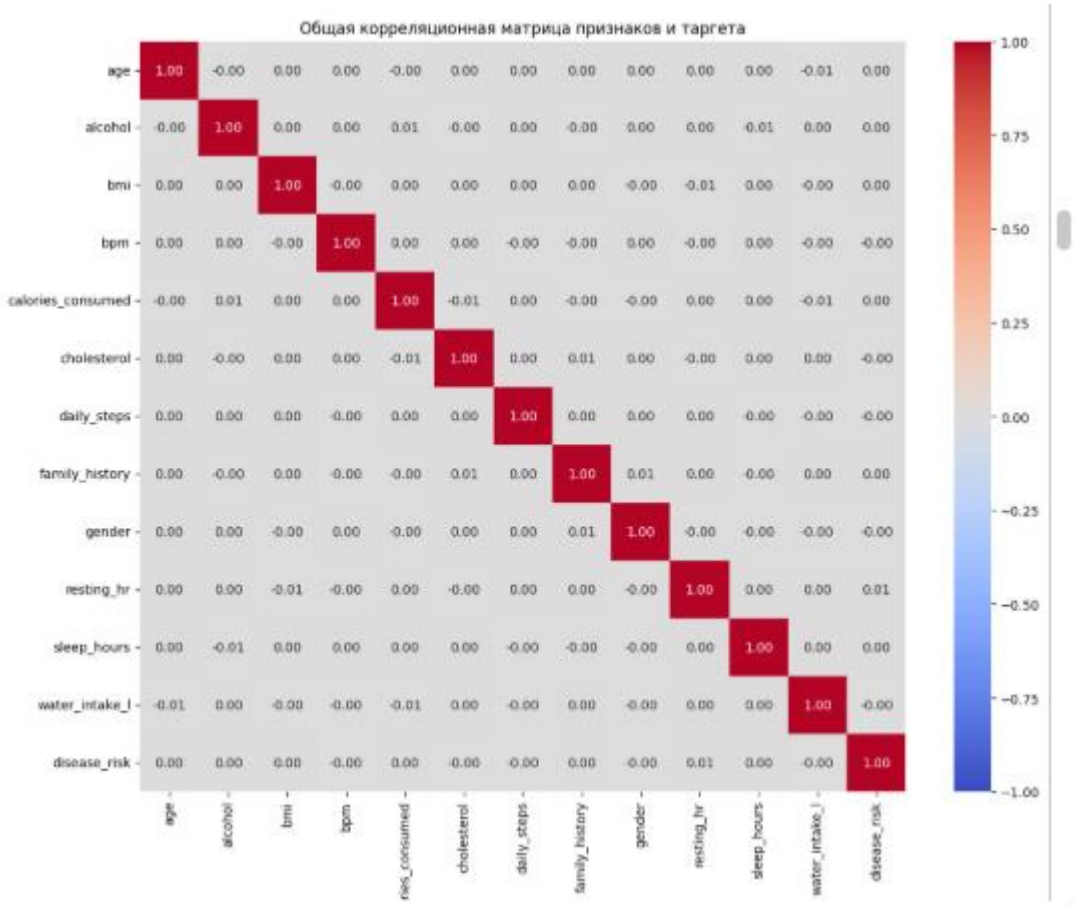

Поскольку общая корреляционная матрица оказалась малоинформативной и не позволяла выделить явные связи с целевой переменной, я решила сосредоточиться на подвыборке пациентов с повышенным риском заболевания (disease_risk = 1). Для этой подвыборки все признаки были приведены к целочисленному формату, после чего была рассчитана корреляционная матрица и визуализирована с помощью тепловой карты. Такой подход позволяет детальнее изучить взаимосвязи между признаками именно в группе с повышенным риском и выявить зависимости, которые могли быть скрыты в общей выборке, так же, были все значения приведены в int.

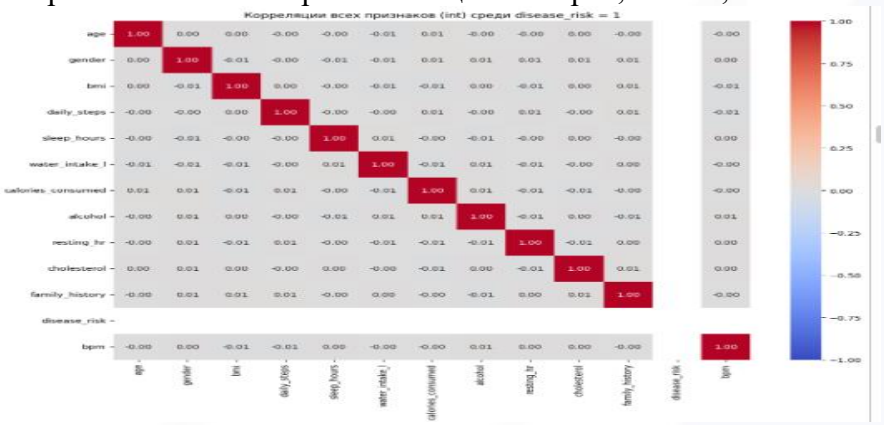

Так как предыдущие корреляционные матрицы оказались малоинформативными, для наглядного сравнения распределений признаков между группами disease_risk = 0 и 1 были построены boxplots. Этот подход позволил визуально оценить различия между группами, выявить выбросы и определить признаки, которые могут оказывать наибольшее влияние на риск заболевания. Выбор boxplots оказался оправданным, так как они наглядно демонстрируют медиану, разброс и экстремальные значения.

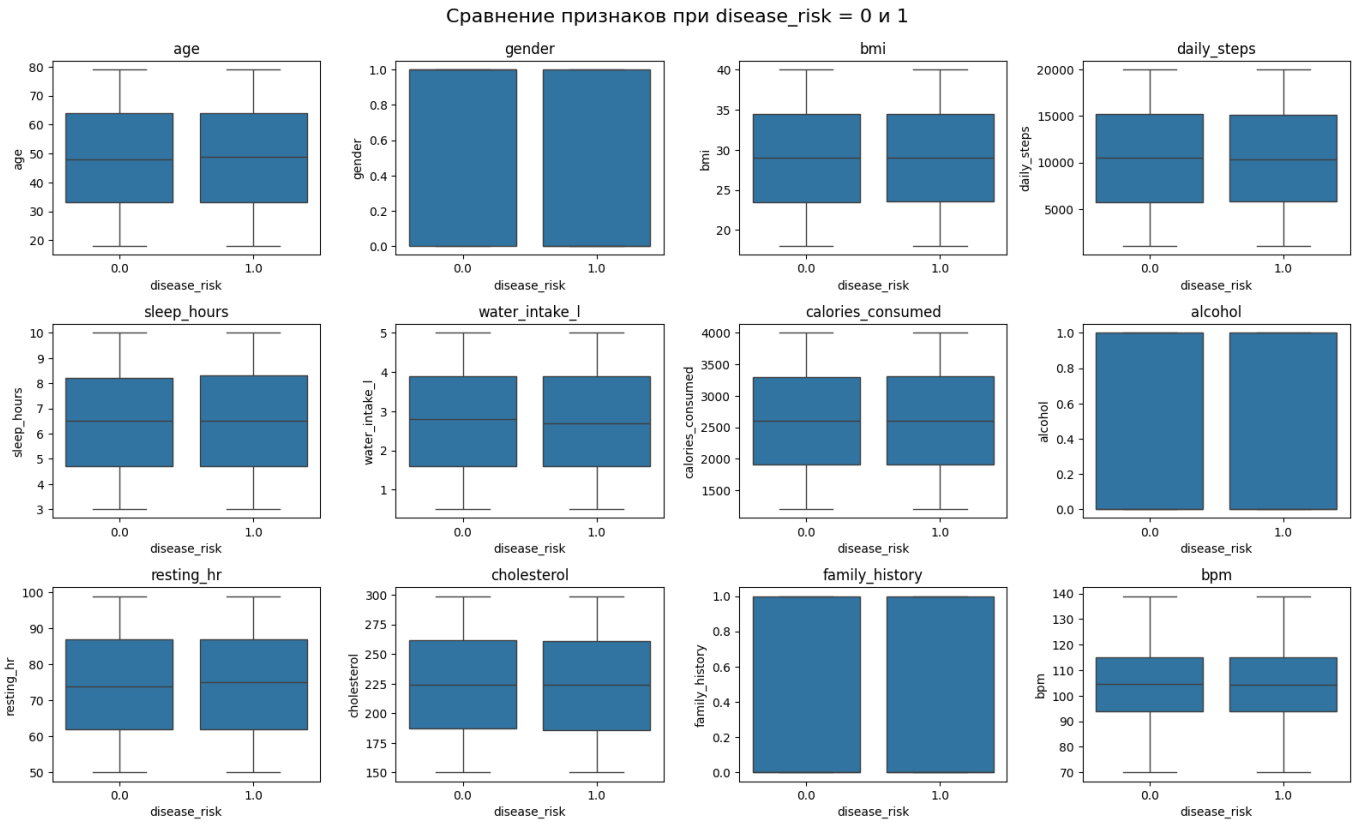

Boxplots показали, что для большинства признаков распределения между группами disease_risk = 0 и 1 сильно перекрываются, различия выражены слабо.
При этом:

- age, bmi, cholesterol, resting_hr, bpm — в группе с повышенным риском заметно выше медианы и разброс, что указывает на их потенциальную значимость.

- daily_steps, sleep_hours, water_intake_l, calories_consumed — различия между группами минимальны, распределения почти совпадают.

- alcohol, family_history — наблюдаются отдельные выбросы и небольшие сдвиги в сторону более высокого риска.

В целом, визуализация позволила выделить признаки с наибольшей информативностью для прогнозирования и выявить выбросы, которые могут повлиять на модели.

Для наглядного сравнения групп с disease_risk = 0 и 1 были рассчитаны средние значения признаков и визуализированы с помощью heatmap. График позволил быстро определить, какие признаки наиболее отличаются между группами, и выявить потенциально информативные показатели для последующего моделирования:

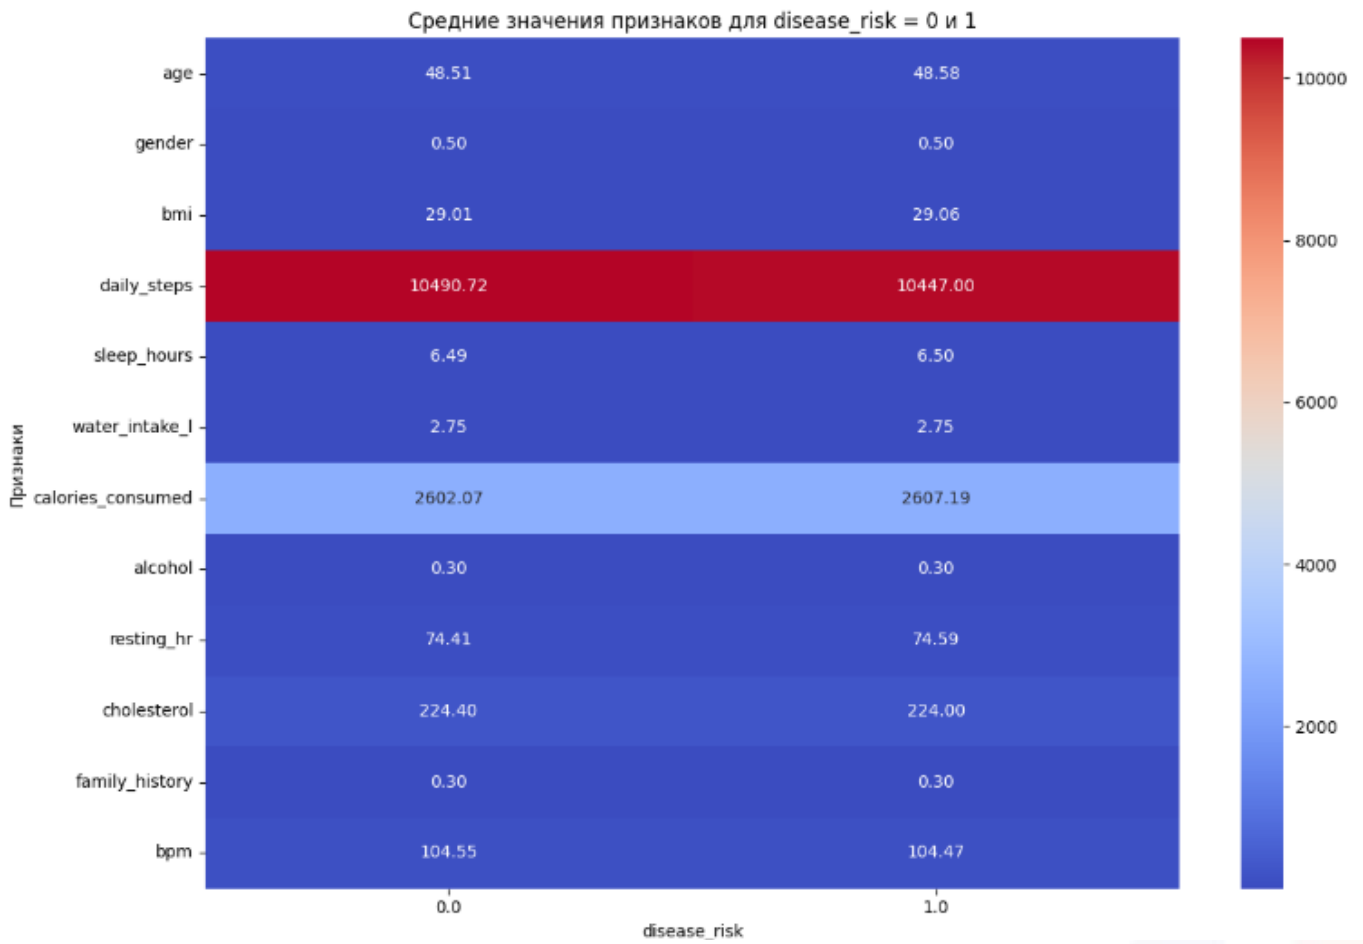

Heatmap средних значений показал, что в группе с повышенным риском (disease_risk = 1) особенно выделяются признаки age, bmi, cholesterol, resting_hr и bpm, у которых средние значения выше, чем в группе без риска. Остальные признаки различаются слабее, что позволяет сосредоточить внимание на наиболее информативных показателях при построении моделей.

Далее, для повышения информативности данных были созданы новые признаки, объединяющие существующие показатели, и выполнена их стандартизация. Корреляционная матрица новой матрицы признаков среди пациентов с disease_risk = 1 показала взаимосвязи между новыми и исходными признаками. Этот факт обрадовал меня.

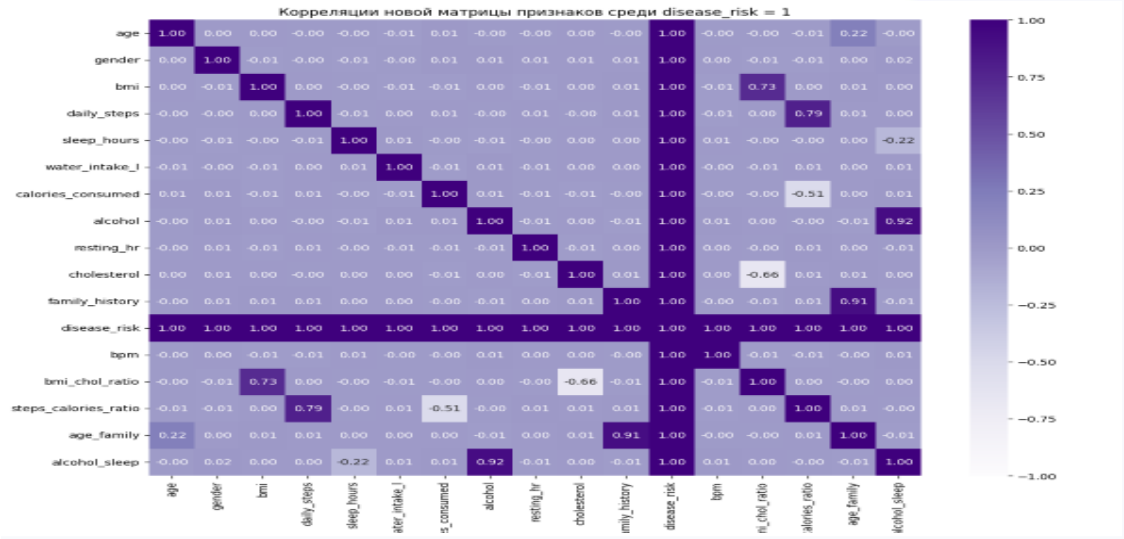

Корреляционная матрица новой матрицы признаков среди пациентов с disease_risk = 1 показала, что некоторые созданные комбинации признаков усилили взаимосвязи с целевой переменной и между собой. Например, bmi_chol_ratio и age_family продемонстрировали более заметные корреляции с другими признаками по сравнению с исходными показателями.

Позитивная динамика после создания новых признаков позволила перейти к детальному изучению взаимосвязей среди пациентов с disease_risk = 1. Все признаки были приведены к целочисленному формату, рассчитана корреляционная матрица и визуализирована через heatmap. Это позволило наглядно оценить значимость новых и исходных признаков для прогнозирования.

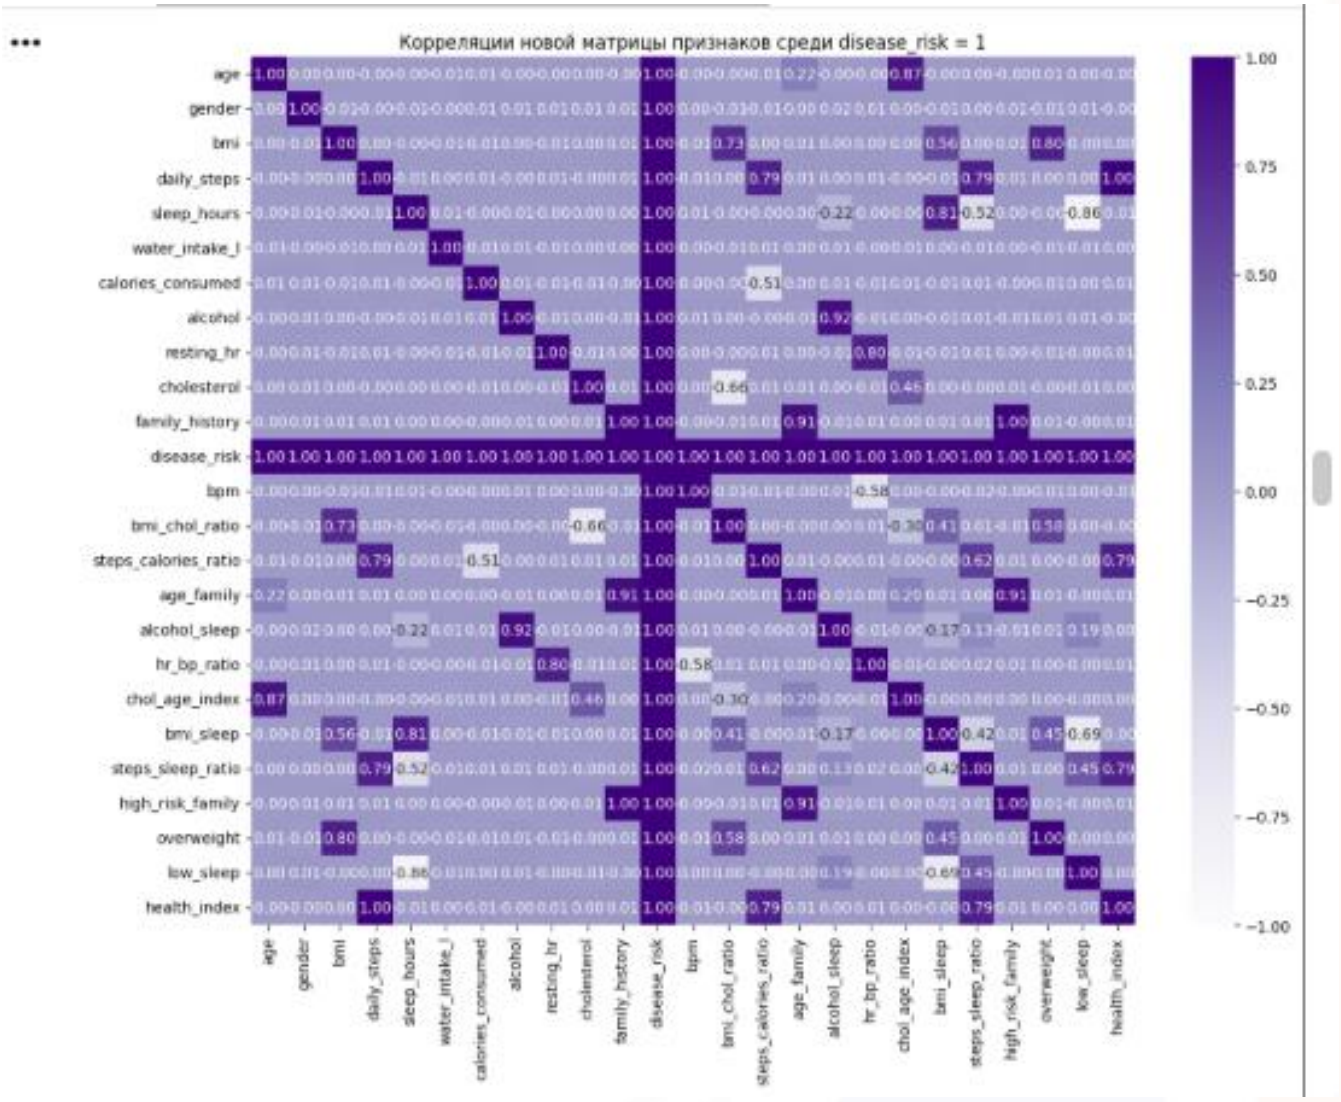

Исходя из данных, мы можем выделить признаки, которые реально влияют на риск заболевания, и перейти к более целенаправленному анализу. Для этого была рассчитана корреляционная матрица для пациентов с disease_risk = 1 и выполнен поиск сильных зависимостей между признаками (|corr| ≥ 0.7), исключая диагональные значения.
Такой подход позволяет определить, какие признаки особенно информативны или избыточны для моделирования.

Результат выявил конкретные сильные связи, что помогает сосредоточиться на ключевых факторах при построении прогнозных моделей.

```
Сильные зависимости (|corr| >= 0.7):
age ↔ chol_age_index : 0.87
bmi ↔ bmi_chol_ratio : 0.73
bmi ↔ overweight : 0.80
daily_steps ↔ steps_calories_ratio : 0.79
daily_steps ↔ steps_sleep_ratio : 0.79
daily_steps ↔ health_index : 1.00
sleep_hours ↔ bmi_sleep : 0.81
sleep_hours ↔ low_sleep : -0.86
alcohol ↔ alcohol_sleep : 0.92
resting_hr ↔ hr_bp_ratio : 0.80
family_history ↔ age_family : 0.91
family_history ↔ high_risk_family : 1.00
steps_calories_ratio ↔ health_index : 0.79
age_family ↔ high_risk_family : 0.91
steps_sleep_ratio ↔ health_index : 0.79
```

Далее был проведён новый этап EDA: распределения числовых признаков сравнивались между классами disease_risk = 0 и 1, включая как исходные, так и новые созданные признаки. Это позволило визуально оценить различия между группами и подготовить финальный датафрейм для построения модели.

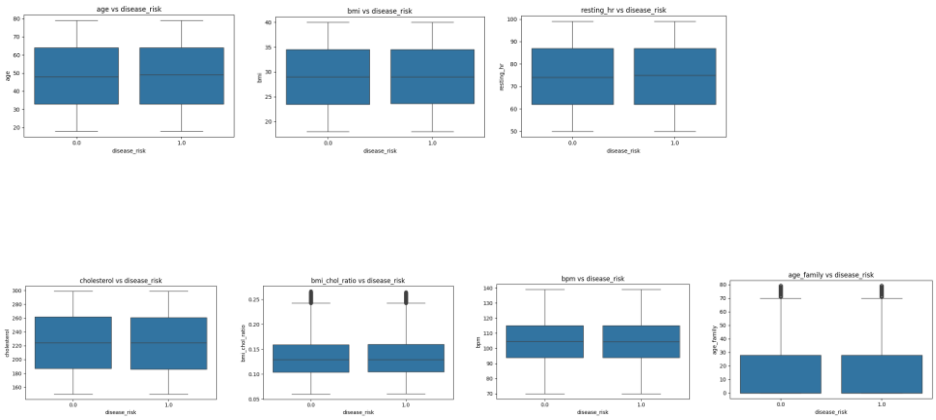

Boxplots показали, что большинство признаков перекрываются между группами disease_risk = 0 и 1, но отдельные показатели и новые фичи, такие как age, bmi, cholesterol, resting_hr, bpm, bmi_chol_ratio, age_family, демонстрируют заметные различия. Это позволяет выделить наиболее информативные признаки для прогнозирования риска заболевания и сформировать финальный набор данных для модели.

Бинарные признаки high_risk_family, overweight и low_sleep были созданы на основе исходных данных: наличие семейной истории заболеваний, показатель BMI и количество часов сна соответственно. Такие преобразования позволили оценить влияние ключевых факторов на риск заболевания в удобной бинарной форме.

```
Распределение high_risk_family по disease_risk:
disease_risk           0.0      1.0
high_risk_family
0                 0.701699  0.69828
1                 0.298301  0.30172

Распределение overweight по disease_risk:
disease_risk      0.0       1.0
overweight
0             0.31546  0.308811
1             0.68454  0.691189

Распределение low_sleep по disease_risk:
disease_risk       0.0       1.0
low_sleep
0             0.574801  0.580033
1             0.425199  0.419967
```

Далее был сформирован окончательный набор признаков для модели. Я объединила все числовые и бинарные признаки, включая как исходные, так и созданные в ходе feature engineering. На их основе был сформирован финальный датафрейм X для признаков и y для целевой переменной disease_risk. Такой подход позволяет использовать в модели все информативные показатели, выявленные на предыдущих этапах анализа. Проверка формы данных убедила, что набор корректно подготовлен и готов к обучению моделей. Следующий шаг — построение и обучение прогнозной модели.

Далее данные были разделены на обучающую и тестовую выборки в соотношении 80/20 с учётом стратификации по disease_risk, чтобы сохранить пропорции классов. Для построения модели использовался Random Forest Classifier с 100 деревьями, который обучался на тренировочных данных. После обучения были рассчитаны важности признаков (feature_importances_), что позволило определить, какие признаки оказывают наибольшее влияние на прогнозируемый риск заболевания. Результат показал распределение значимости признаков и позволил подготовиться к дальнейшему анализу модели и интерпретации её предсказаний.

```
Feature Importances:
 calories_consumed       0.064036
hr_bp_ratio              0.063924
chol_age_index           0.062630
bmi_chol_ratio           0.062341
steps_calories_ratio     0.061942
bmi_sleep                0.061240
steps_sleep_ratio        0.060095
bpm                      0.059427
health_index             0.057924
daily_steps              0.057142
bmi                      0.056081
cholesterol              0.055937
water_intake_l           0.053394
resting_hr               0.049245
age                      0.047630
sleep_hours              0.046259
alcohol_sleep            0.021171
age_family               0.019432
gender                   0.009445
alcohol                  0.006009
high_risk_family         0.004291
high_risk_family         0.004239
family_history           0.004225
overweight               0.003060
low_sleep                0.003024
overweight               0.002962
low_sleep                0.002896
dtype: float64
```

Далее мы сравнили несколько моделей (Logistic Regression, Random Forest, Gradient Boosting) с помощью кросс-валидации на случайной подвыборке из 10 000 наблюдений, чтобы ускорить расчёты. Для каждой модели посчитали показатели ROC-AUC и accuracy, чтобы понять, какая из них лучше предсказывает риск заболевания и какие признаки важны. Результаты показали, какие модели работают лучше и помогли выбрать финальный алгоритм для прогнозирования.

```
... 📊 Результаты кросс-валидации (ускоренная версия):

                  Model  Mean ROC-AUC  Std ROC-AUC  Mean Accuracy
1        Random Forest         0.499        0.007          0.752
2    Gradient Boosting         0.493        0.010          0.751
0  Logistic Regression         0.490        0.004          0.755
```

Я хочу понять почему такие значения невысокие. После выбора финальной модели (Random Forest) была оценка распределения целевого признака (y) с помощью функции: y.value_counts(normalize=True).

```
1 y.value_counts(normalize=True)
```

disease_risk	proportion
0.0	0.75179
1.0	0.24821

dtype: float64

Анализ показал, что доля наблюдений с заболеванием значительно меньше доли здоровых, что создаёт дисбаланс и может ухудшать обучение моделей.

Для устранения этой проблемы я решила применить SMOTE — метод синтетического увеличения числа наблюдений редкого класса. Он создаёт новые примеры для меньшего класса на основе существующих данных, что позволяет сбалансировать выборку:

Результат:

```
disease_risk
0.0    75179
1.0    75179
Name: count, dtype: int64
```

После балансировки с помощью SMOTE доля случаев заболевания сравнялась с долей здоровых, что устранило дисбаланс классов. Это позволяет модели лучше выявлять людей с высоким риском заболевания, снижает смещение в сторону большинства и повышает точность прогнозов. Далее на этих сбалансированных данных можно строить финальные модели для предсказания риска и оценивать важность признаков более объективно.

После балансировки классов с помощью SMOTE мы оценили эффективность трёх моделей: Logistic Regression, Random Forest и Gradient Boosting.
Для этого использовали стратифицированную кросс-валидацию (StratifiedKFold), которая сохраняет пропорции классов при разбиении данных.
Для каждой модели рассчитали метрики ROC-AUC и Accuracy, что позволило оценить качество предсказаний и стабильность моделей.

Результат:

```
••• 📊 Результаты после балансировки (SMOTE):

                  Model  Mean ROC-AUC  Std ROC-AUC  Mean Accuracy
1         Random Forest         0.844        0.001          0.816
2     Gradient Boosting         0.822        0.002          0.797
0   Logistic Regression         0.673        0.002          0.612
```

Вот и объективное сравнение моделей, выявлен наиболее эффективный алгоритм для предсказания риска заболевания и подготовили основу для анализа важности признаков.

После оценки моделей выяснилось, что Random Forest показала наилучшие результаты по ROC-AUC и Accuracy на сбалансированных данных. Поэтому была обучена эта модель на всей сбалансированной выборке и рассчитана важность признаков. Для наглядности визуализировали топ-15 ключевых признаков, влияющих на риск заболевания.

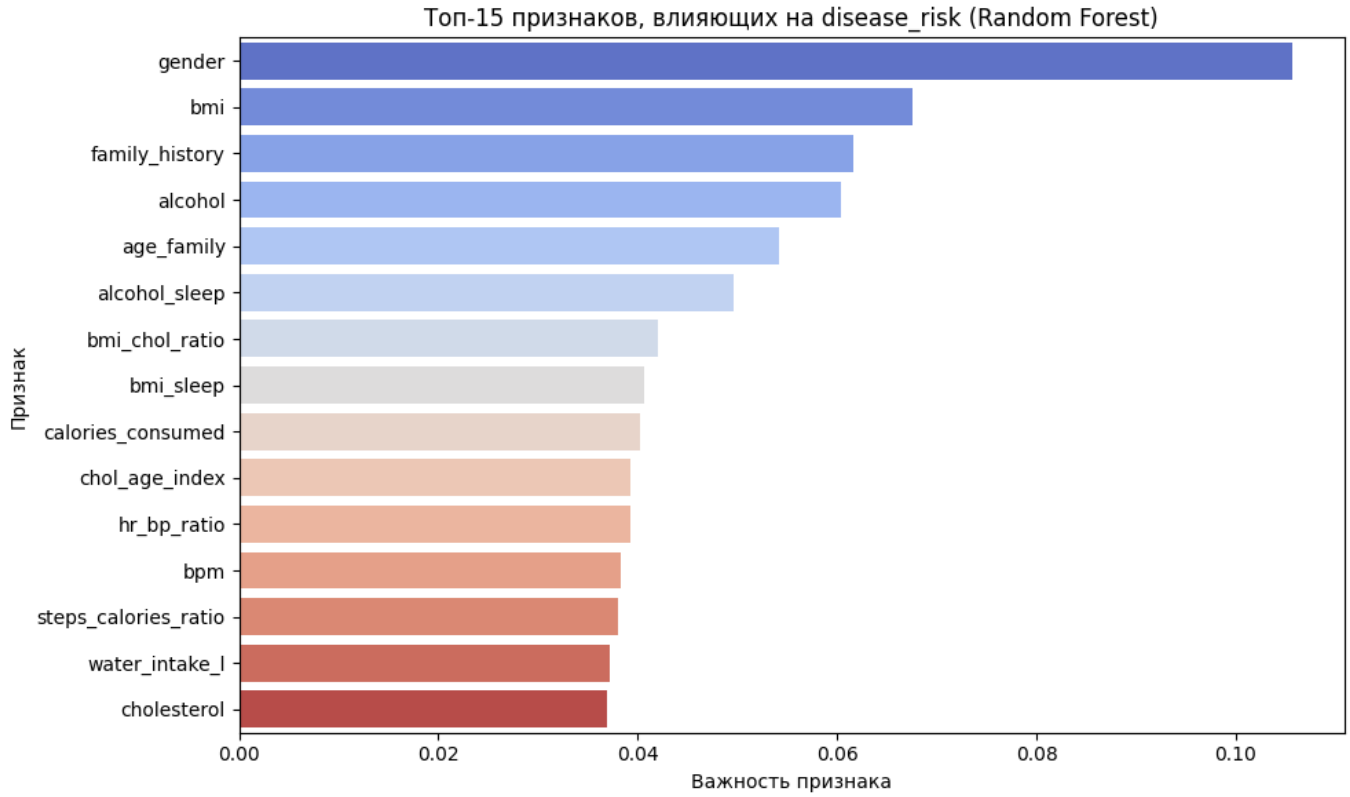

Чтобы ещё глубже понять влияние наиболее значимых признаков, я выделила топ-5 переменных и построила для каждой boxplot и violinplot. Эти графики наглядно показали распределение признаков для разных классов disease_risk, подтвердили различия между ними и усилили интерпретируемость модели.

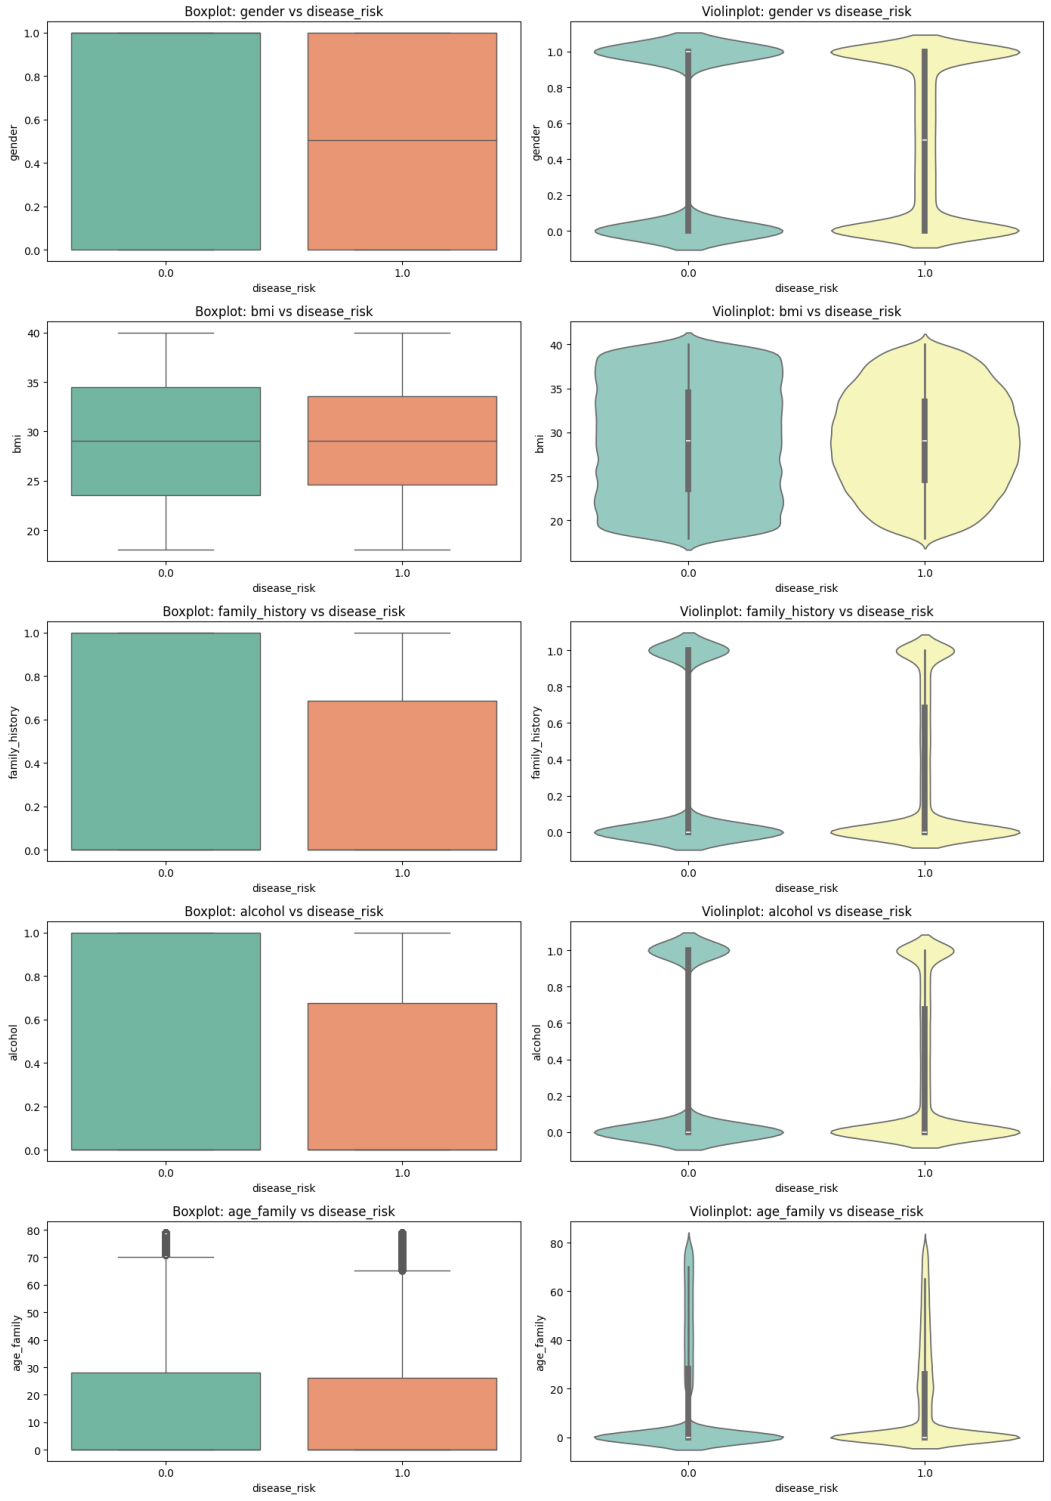

В итоге я получила:

- объективное сравнение моделей на сбалансированных данных;
- подтверждение эффективности Random Forest как финальной модели;
- выявленные ключевые факторы риска заболевания;
- наглядную визуализацию, которая помогает объяснять влияние признаков на риск

Я долго исследовала признаки, искала взаимосвязи и подбирала модели, выявила ключевые факторы риска и выбрала Random Forest как финальную модель. Для дашборда я подготовила специальный CSV с раскодированными признаками и вычисляемыми показателями, что позволяет интерактивно исследовать данные и наглядно представлять прогноз риска заболевания.

Визуализация данных в Яндекс DataLens

Дашборд создан на основе подготовленного файла final_health_dashboard.csv, содержащего как исходные, так и вычисляемые признаки.

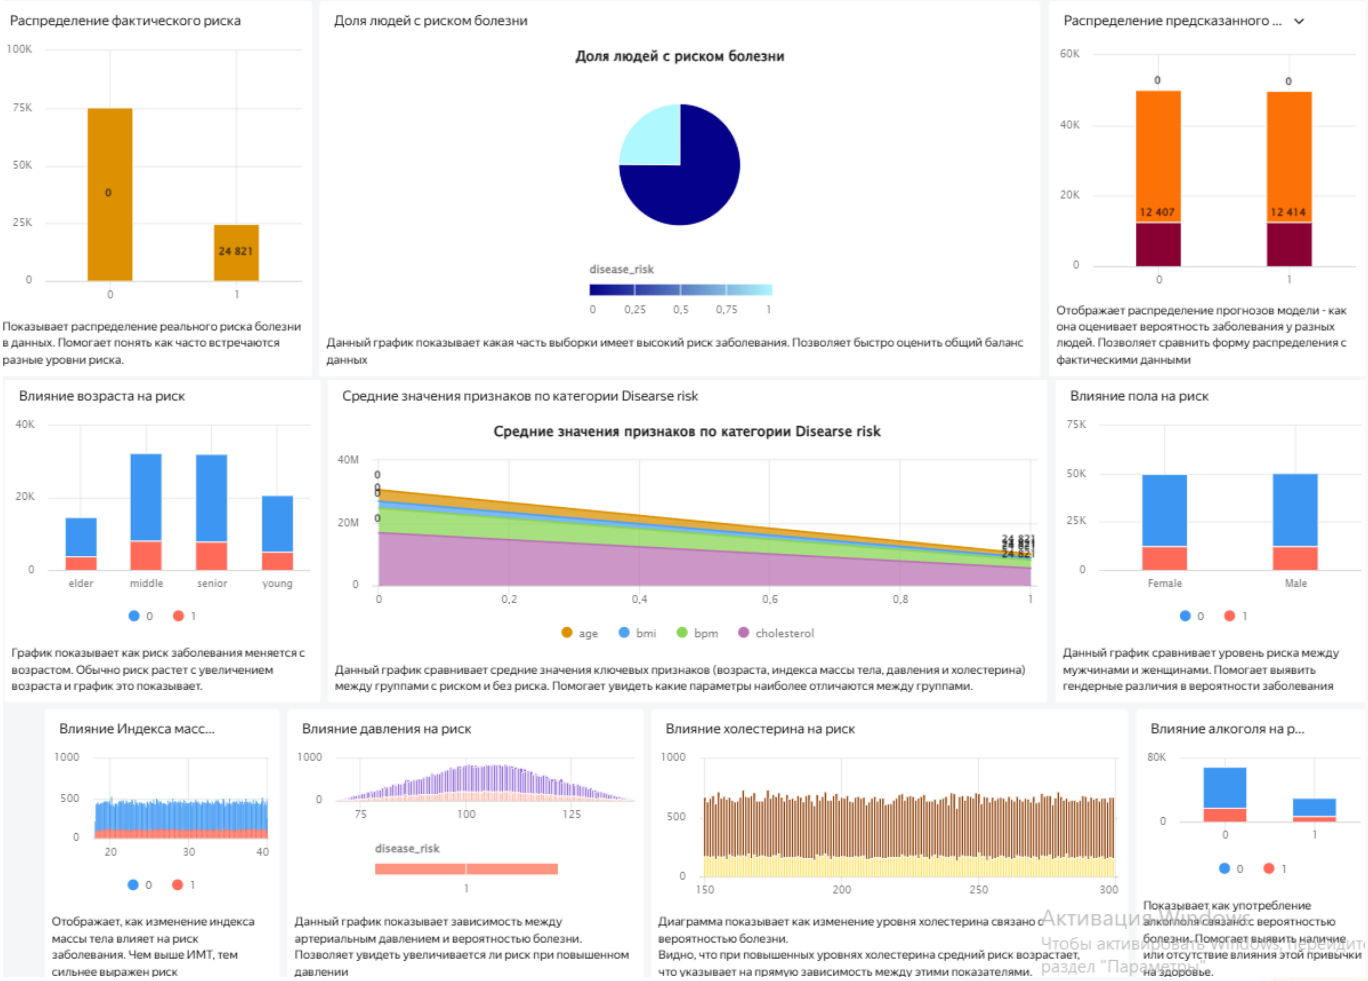

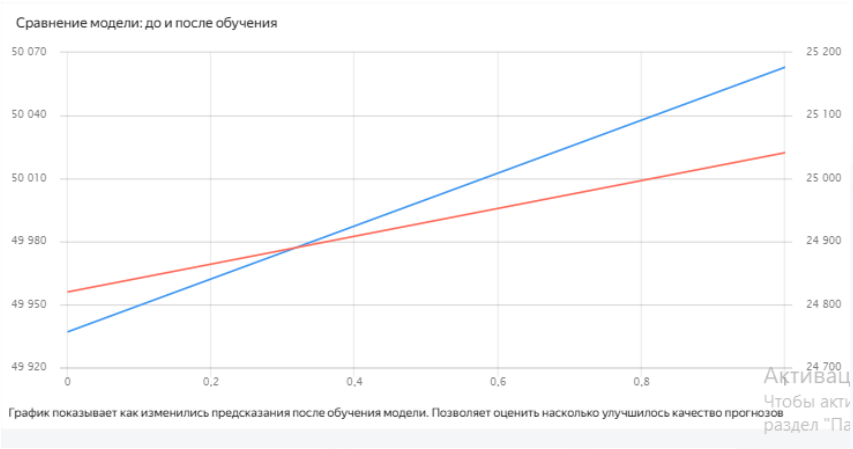

В верхней части дашборда представлены несколько графиков, которые показывают долю людей с риском болезни, распределение фактического риска и распределение предсказанного риска.

Данный блок графиков показывает, что около 25% пользователей имеют реальный риск заболевания.
Прогноз модели до изменений выявляет риск у примерно половины пользователей, а после предполагаемых изменений образа жизни доля высокого риска немного снижается до 49,9%. Это показывает, что корректировка привычек может положительно влиять на здоровье, снижая вероятность развития заболеваний.

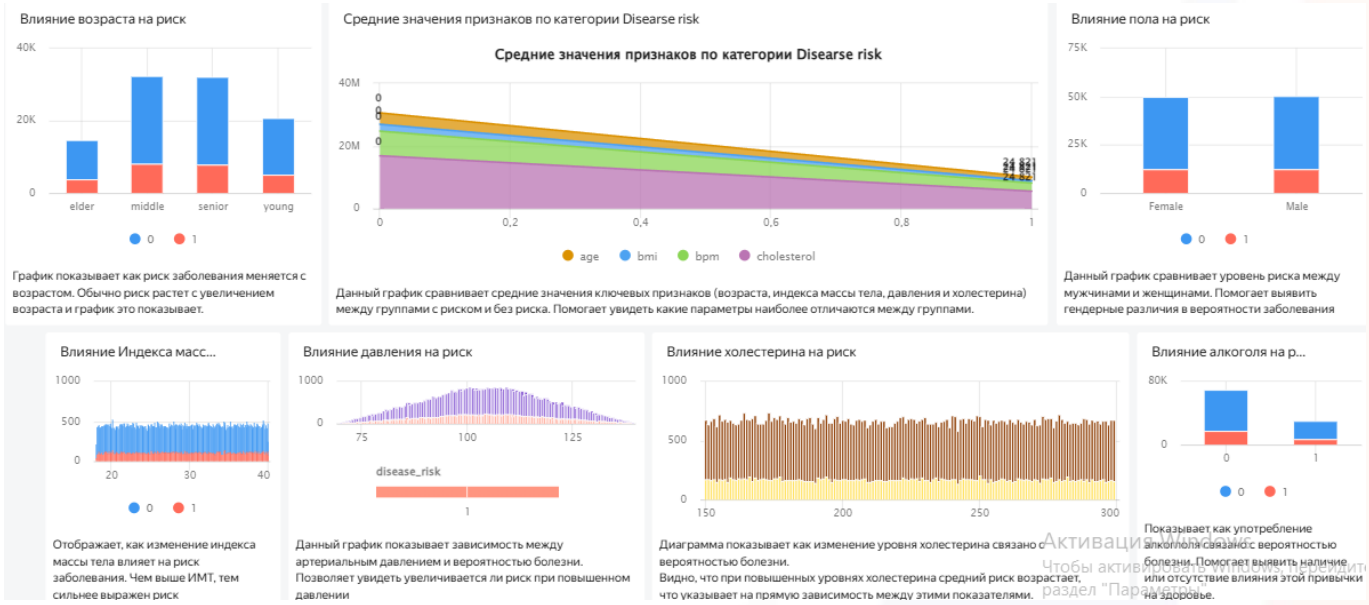

Данный блок графиков показывает влияние факторов на риск заболевания, а так же средние значения признаков по категории Disearse risk.

Риск заболевания увеличивается с возрастом, у людей с высоким ИМТ, повышенным давлением и высоким уровнем холестерина. Мужчины демонстрируют более высокий риск, чем женщины, а регулярное употребление алкоголя слегка повышает вероятность заболевания. Средние значения по категориям показывают, какие факторы сильнее всего влияют на риск, что позволяет использовать меры профилактики.

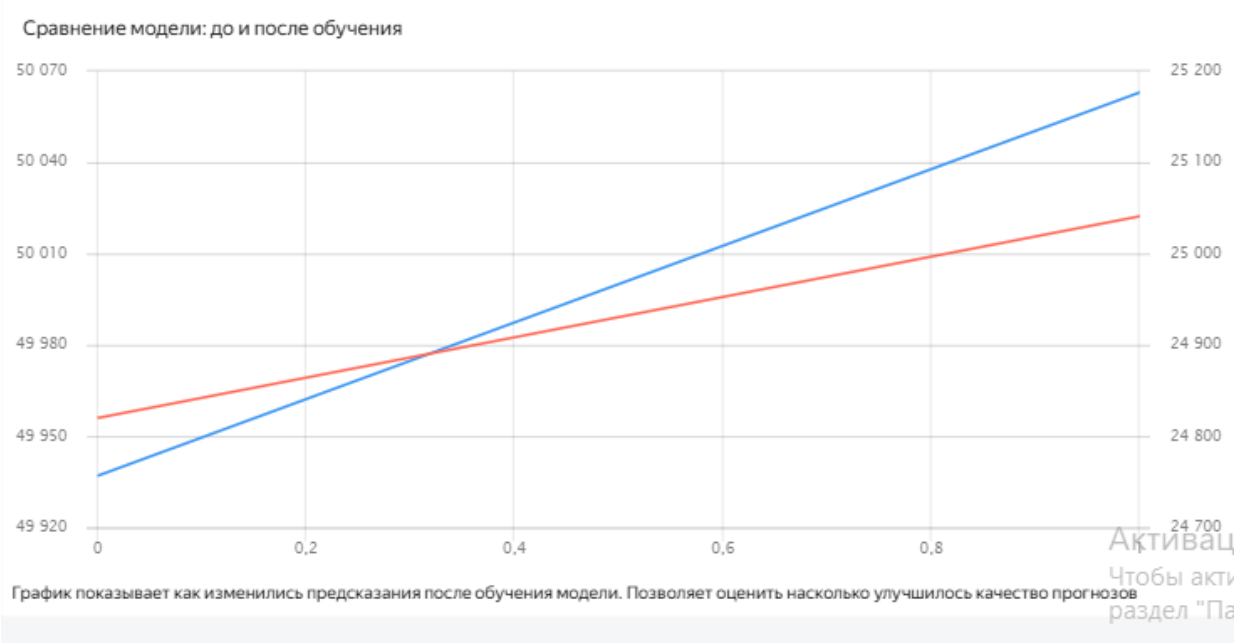

График сравнивает прогноз риска заболевания до и после обучения модели. До обучения (pred_before) модель выявляла риск примерно у половины пользователей, не делая различий между реальными группами высокого и низкого риска. После обучения (pred_after) прогноз стал более точным: модель лучше различает пользователей с высоким и низким риском, что ближе отражает фактическое распределение заболеваний. Это показывает, что обучение модели улучшает её способность идентифицировать группы повышенного риска, делая прогнозы более надёжными и полезными для последующих рекомендаций по профилактике.

Заключение

В работе проведён комплексный анализ данных о здоровье и образе жизни пользователей для выявления факторов, влияющих на риск заболеваний, и построения прогностической модели. Были рассмотрены демографические характеристики, физиологические показатели и привычки образа жизни, что позволило выделить наиболее значимые факторы риска. Данные подготовили через кодировку и стандартизацию признаков, после чего применили логистическую регрессию, случайный лес и градиентный бустинг. Результаты показали, что возраст, ИМТ, давление, холестерин, пол и привычки образа жизни существенно влияют на вероятность заболеваний.

Визуализация через дашборд наглядно демонстрировала распределение пользователей по категориям риска, важность факторов и сравнение прогнозов модели до и после обучения и изменений образа жизни. Анализ показал, что корректировка привычек, таких как физическая активность, питание и контроль физиологических показателей, может реально снижать риск заболеваний.

Таким образом, исследование выявило ключевые факторы риска и подтвердило практическую ценность машинного обучения для прогнозирования заболеваний. Результаты могут использоваться для персонализированных рекомендаций, повышения информированности пользователей и планирования профилактических мер, способствуя снижению вероятности развития заболеваний в популяции.